

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

«МИРЭА – Российский технологический университет» РТУ МИРЭА

ИКБ направление «Киберразведка и противодействие угрозам с применением технологий искусственного интеллекта» 10.04.01

Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

Практическая работа №4

по дисциплине

«Анализ защищенности систем искусственного интеллекта»

Группа: ББМО-01-22 Выполнил: Феденёв А.В.

Проверил: Спирин А.А.

Устанавливаем пакет art

Загружаем все необходимые библиотеки

```
from __future__ import absolute_import, division, print_function, unicode_literals
    import os, sys
    from os.path import abspath
    module_path = os.path.abspath(os.path.join('...'))
    if module path not in sys.path:
      sys.path.append(module_path)
    import warnings
    warnings.filterwarnings('ignore')
    import tensorflow as tf
    tf.compat.v1.disable_eager_execution()
    tf.get_logger().setLevel('ERROR')
    import tensorflow.keras.backend as k
    from tensorflow.keras.models import Sequential
    from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Activation, Dropout
    import numpy as np
    import matplotlib.pyplot as plt
    %matplotlib inline
    from art.estimators.classification import KerasClassifier
    from art.attacks.poisoning import PoisoningAttackBackdoor, PoisoningAttackCleanLabelBackdoor
    from art.attacks.poisoning.perturbations import add_pattern_bd
    from art.utils import load_mnist, preprocess, to_categorical
    from art.defences.trainer import AdversarialTrainerMadryPGD
```

Загружаем датасет MNIST и разделяем его на обучающую и тестовую выборки

```
[3] (x_raw, y_raw), (x_raw_test, y_raw_test), min_, max_ = load_mnist(raw=True)

n_train = np.shape(x_raw)[0]

num_selection = 10000

random_selection_indices = np.random.choice(n_train, num_selection)

x_raw = x_raw[random_selection_indices]

y_raw = y_raw[random_selection_indices]
```

Выполняем отравление данных

```
percent_poison = .33
    x_train, y_train = preprocess(x_raw, y_raw)
    x_train = np.expand_dims(x_train, axis=3)

x_test, y_test = preprocess(x_raw_test, y_raw_test)
    x_test = np.expand_dims(x_test, axis=3)

n_train = np.shape(y_train)[0]
    shuffled_indices = np.arange(n_train)
    np.random.shuffle(shuffled_indices)
    x_train = x_train[shuffled_indices]
    y_train = y_train[shuffled_indices]
```

Пишем функцию create_model() для создания последовательной модели из 9 слоев

```
def create_model():
    model = Sequential()
    model.add(Conv2D(32, (3, 3), activation='relu', input_shape=(28, 28, 1)))
    model.add(Conv2D(64, (3, 3), activation='relu'))

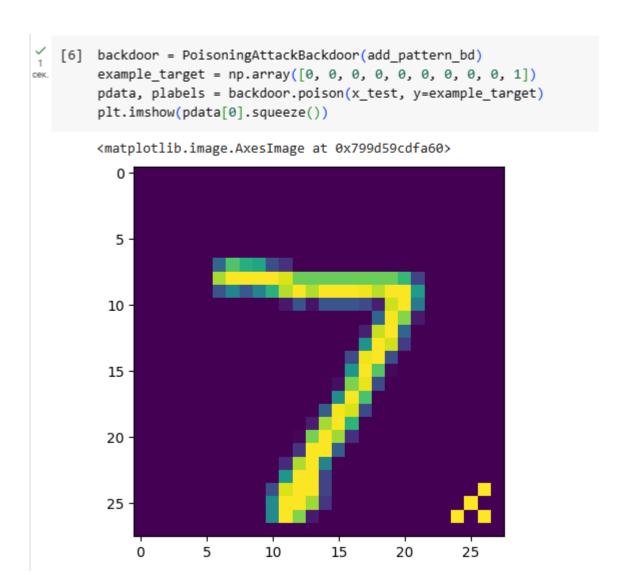
    model.add(MaxPooling2D(pool_size=(2, 2)))

    model.add(Dropout(0.25))

    model.add(Dropout(0.25))

    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dropout(0.25))
    model.add(Dro
```

Создаем атаку



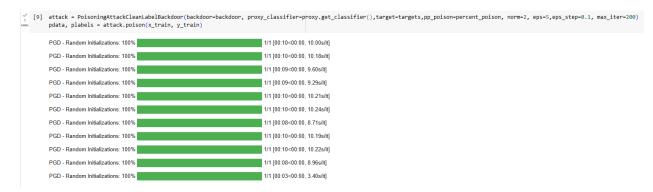
Определяем целевой класс атаки

```
(7) targets = to_categorical([9], 10)[0]
```

Создадим модели и обучим

```
| Total Precompute adv samples: 100% | Model = KerasClassifier(create_model()) | Model = KerasClassifier(create_mo
```

Выполним атаку



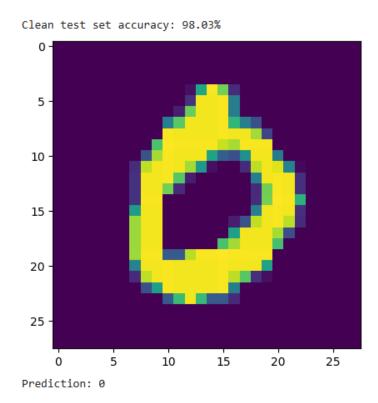
Создадим отравленные примеры данных и отобразим одно из отравленных

```
[10] poisoned = pdata[np.all(plabels == targets, axis=1)]
     poisoned_labels = plabels[np.all(plabels == targets, axis=1)]
     print(len(poisoned))
     idx = 0
     plt.imshow(poisoned[idx].squeeze())
     print(f"Label: {np.argmax(poisoned_labels[idx])}")
     983
     Label: 9
        0 -
        5
       10 -
       15 -
      20
      25 -
           0
                    5
                            10
                                     15
                                              20
                                                       25
```

Обучим модель на отравленных данных

```
[11] model.fit(pdata, plabels, nb_epochs=10)
```

Выполним проверку работы модели в обычных условиях на чистых данных

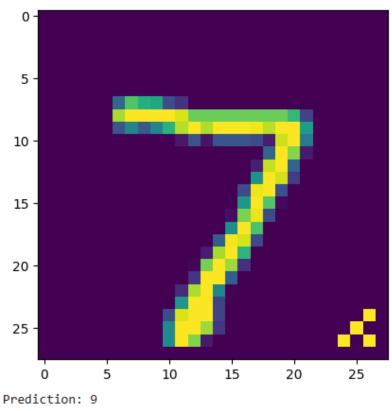


Проверим работу модели на отравленных данных

```
int("NPoison test set accuracy: %.2f%%" % (poison_acc * 100))

c = 0 # index to display
    plt.imshow(px_test[c].squeeze())
    print("Prediction: " + str(poison_preds[c])))
```

Poison test set accuracy: 0.75%



После атаки точность снизилась и результат предсказан неправильно.